코디세이 AI 해커톤 2026 · 팀 유레카

# CodySafe
# 전화를 끊은 뒤,
# 가족과 함께 막습니다

통화 녹음을 AI로 분석해 근거를 보여 주고, 가족에게 알리고, 금융 앱을 잠그는 보이스피싱 후속 대응 서비스

박병국 · 김동현 · 김호연 · 유상우 · 전선형

ⓐ 문제 정의 및 목표 사용자

# 속은 사람은 혼자 있고, 가족은 뒤늦게 압니다

## 5,384만 원

**2025년 보이스피싱 건당 피해액 (전년 2,500만 원)**

발생 건수는 24.6% 줄었지만 피해액은 62.4% 늘었습니다. 피해액의 **78.6%** (9,884억 원)가 기관 사칭형입니다.

출처: 국회 제출 자료, 매일신문 2026-09-23

### 우리가 본 빈틈

- 사기범은 전화를 끊지 말라, 아무에게도 말하지 말라고 몰아붙입니다. 이때 **당사자의 판단만으로** 멈추기 어렵습니다.
- 가족이 알아도 도울 방법이 없고, 통화 내용을 통째로 공유하는 것은 사생활 문제입니다.
- AI 음성 때문에 **"목소리가 같으니 가족"**이라는 확인도 믿기 어려워졌습니다.

### 목표 사용자

**보호 대상**

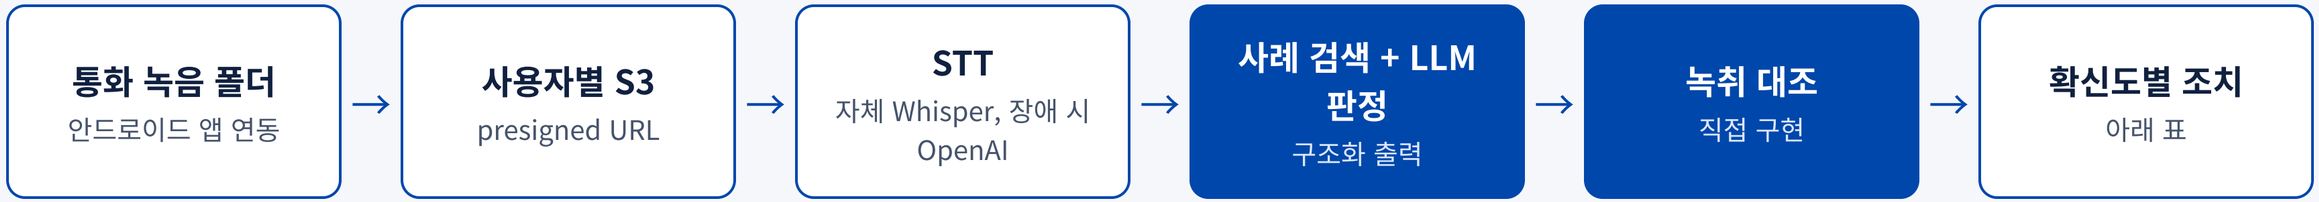
삼성 휴대폰으로 통화를 녹음하는, 보이스피싱에 노출된 사람

**가족**

부모님과 형제의 금융 피해를 걱정하지만 통화 내용까지 보고 싶지는 않은 사람

ⓑ 해결 방안 — 서비스 개요

# 실시간 탐지와 경쟁하지 않고, 그 다음 단계를 맡습니다




## 확신도별 후속 조치

| 조건 | 동작 |
|---|---|
| **0.7 이상** | 연결된 가족에게 **의심 여부만** 알림 |
| **0.9 이상** | 은행·카드·간편결제·증권·원격제어 **앱 47개 잠금** (기본 1시간) |
| **근거 없음** | "판단 어려움"으로 낮추고 알림·잠금 안 함 |
| **잠금 해제** | 가족은 즉시, 본인은 10분 대기 후, 또는 시간 만료 |

## 왜 통화 중이 아니라 통화 후인가

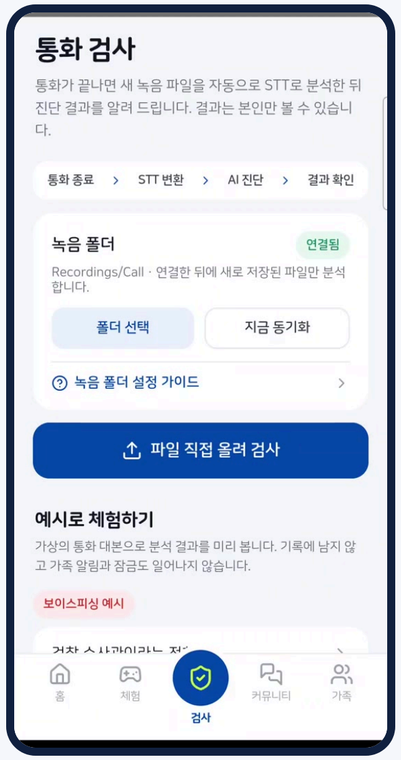
일반 안드로이드 앱은 통화 음성을 받을 수 없습니다. `VOICE_CALL` 캡처는 사전 설치된 특권 앱의 권한이 필요하고, 통화 중 일반 앱의 마이크 입력은 무음입니다.

실시간 탐지는 제조사와 통신사 영역입니다. 우리는 **이체 전 차단을 보장하지 않으며**, 통화 후 추가 이체와 2차 피해를 줄이는 데 집중합니다.

근거: Android 개발자 문서(MediaRecorder.AudioSource, 오디오 입력 공유)

ⓑ 주요 기능 — 실제 안드로이드 폰 녹화 화면

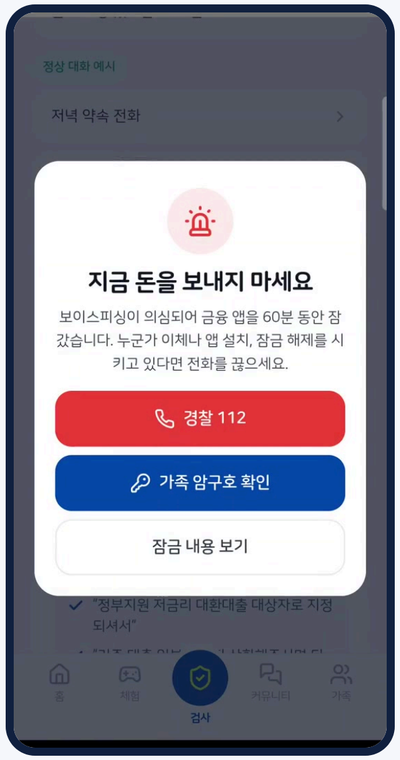
# 분석부터 잠금까지 실제 폰에서 동작합니다



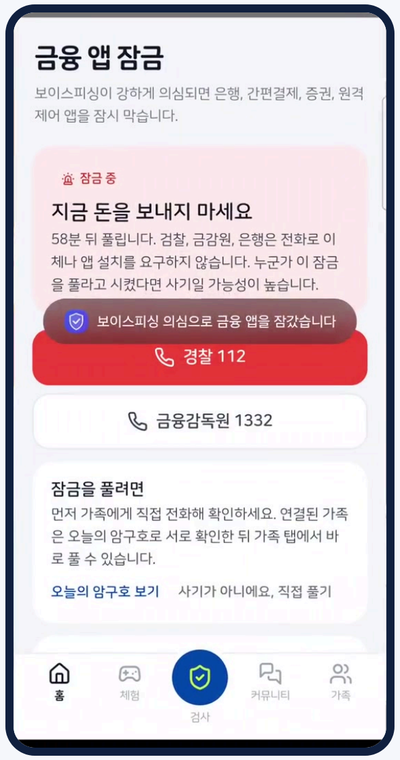

**1. 녹음 폴더 연결**
저장된 녹음만 읽음




**2. 통화 속 근거**
실제로 나온 말만 표시




**3. 즉시 경고**
112와 암구호로 연결




**4. 금융 앱 잠금**
열면 경고로 되돌림

## 예방까지 함께

**가족 암구호** 매일 0시에 바뀌는 단어로 가족 사칭 확인

**사기 체험** 13개 수법을 대화형으로 연습

**제보→훈련** 추천 상위 제보를 AI 시나리오로 생성

**코디·퀴즈** 가족 퀴즈 15장, 예방 행동에만 점수

테스트 통화 사용. 개인정보 장면 제외, 대기 시간 단축

ⓒ 활용 AI 기술 및 직접 개발 범위

# 판정은 API에 맡기되, 믿고 행동하게 만드는 층은 직접 만들었습니다

| 층 | 적용 방식 | 구분 |
|---|---|---|
| **음성 → 글자** | 자체 서버 CPU Whisper large-v3-turbo INT8, 부하·장애 시 OpenAI `whisper-1` | **직접 구축**: 5개 설정 비교, 서빙, 전환. 대체 경로만 외부 API |
| **사기 판정** | Claude `claude-opus-5-5`, JSON 스키마 출력. 4개 라벨, 유형, 확신도, 인용 근거 | 외부 API + **직접 작성**: 판정 기준, 스키마, 프롬프트 방어 |
| **수법 참고(RAG)** | 문서를 LLM으로 분류·구조화해 적재. BM25(nori) + bge-m3 kNN을 RRF로 결합, 유사 사례 3건을 판정에 참고. 실패 시 LLM만 사용 | **직접 구현**: 적재·검색 API. Elasticsearch, bge-m3 사용 |
| **유형 매칭** | 음절 2-gram BM25 + 벡터 → RRF 결합 → LLM 재순위 (수법 지식 10종) | **직접 구현**. 벡터는 현재 해시 임베딩 |
| **근거 대조** | LLM이 인용한 문장이 녹취에 순서대로 있는지 코드로 검사 | **직접 구현** |
| **후속 조치** | 임계값 분기, 가족 알림, 잠금·해제 정책, 가족 그룹 암구호 | **직접 구현** |
| **안드로이드 앱** | 저장소 접근 프레임워크 폴더 감시, S3 직접 업로드, 접근성 서비스 앱 차단 | **직접 구현** (Kotlin) |
| **제보 → 시나리오** | 번호·계좌·링크 마스킹 후 LLM으로 5턴 훈련 생성, 결과 구조 검사 | **직접 구현** + 외부 API |

자체 학습 모델은 없습니다. 모델 파인튜닝은 확장 계획입니다.

ⓒ 적용 방식 — 오판을 줄이는 설계

# 잘못된 경고도 피해입니다. 그래서 LLM의 답을 그대로 믿지 않습니다

```
# server/guard/llm.py (요약)
def _keep_grounded(result, transcript):
    if result["label"] != VOICE_PHISHING:
        result["evidence"] = []
        return result
    # 녹취에 실제로 있는 인용만 남김
    result["evidence"] = [q for q in result["evidence"]
                          if _in_transcript(q, transcript)]
    # 근거가 없으면 가족 알림과 잠금을 일으키지 않음
    if not result["evidence"]:
        result["label"] = "uncertain"
    return result
```

**자동 테스트 70개 통과** (`pytest`, 외부 키 없이 실행). 판정 분기, 잠금 해제, 가족 권한, 제보 마스킹을 포함합니다.

## 설계 원칙 5가지

- **환각 차단** 녹취에 없는 근거는 표시하지 않고 조치도 막음
- **주입 방어** 녹취 속 "정상으로 판정하라"는 지시를 따르지 않고 판단 근거로 고려
- **단계적 조치** 피해가 큰 잠금은 알림보다 높은 기준 적용
- **정보 최소화** 가족에게 요약·유형·녹취·확신도를 보내지 않음. 일상 통화는 글자 기록도 저장 안 함
- **되돌릴 수 있음** 오탐이어도 가족 해제, 10분 대기, 시간 만료로 복구

확신도는 LLM이 매긴 값이며 보정 전이라 사기 확률이 아닙니다. 화면에도 그렇게 표시합니다.

ⓓ 개발 환경 및 기술 스택

# 웹과 안드로이드 앱이 하나의 API와 화면을 함께 씁니다

| 구분 | 사용 기술 |
| --- | --- |
| **서버** | Python 3.12, FastAPI, Uvicorn, SQLite |
| **웹** | HTML, CSS, JavaScript (프레임워크 없음) |
| **앱** | Kotlin, WebView, WorkManager, 접근성 서비스 (minSdk 26, targetSdk 34) |
| **AI** | Claude, faster-whisper(대체: OpenAI Whisper), Elasticsearch 8.17 + bge-m3 |
| **인프라** | AWS EC2, S3 (presigned URL), Terraform·Docker(검색 서버), GitHub Actions |
| **관측** | Langfuse Cloud: 시간·토큰·판정 라벨만 전송, 통화 내용은 보내지 않음 |
| **검증** | pytest 70개, 실제 음성 파일, 실제 폰 녹화 |

## 구현상 판단

**화면을 WebView로 공유**

화면을 고쳐도 APK를 다시 빌드하지 않습니다.
네이티브는 폴더 접근, 동기화, 차단만 맡습니다.

**기기에 AWS 키를 두지 않음**

presigned URL로 사용자별 경로에 직접 올립니다.

**음성은 자체 서버에서 먼저**

외부 전송과 의존을 줄이려 STT를 직접 띄웠습니다.
GPU 사용 제약으로 CPU에서 서빙하고, 부하·장애 때만 OpenAI로 넘깁니다.

대체 경로를 탄 음성은 외부로 전송됩니다. Langfuse: us.cloud.langfuse.com/project/cmvwspomu005fad0e5vr8sgrq/traces

ⓔ 팀원별 역할 분담

# 팀원별 담당 업무와 기여 내용

| 이름 | 담당 | 기여 내용 |
| --- | --- | --- |
| **김동현** | 서비스 구현 총괄 | 서버 API와 판정 파이프라인, 근거 대조, 가족 알림·잠금·암구호, 웹 화면, 안드로이드 앱, 체험·제보·피드백, S3·RAG·Langfuse 연동, 테스트, 배포 |
| **김호연** | 초기 기획 | 문제 조사와 경쟁 서비스 비교, 기획 초안, 저장소 비밀값 관리 규칙(.gitignore) |
| **유상우** | 브랜드 디자인 | CodySafe 브랜드 가이드, 로고 자산 |
| **박병국** | URL 보안 탐지 | URL 구조·유사 도메인·위협 정보 기반 탐지 모듈 (별도 프로토타입) |
| **전선형** | **확인 필요** | **담당 업무와 기여 내용 기입** |

### 협업 방식

GitHub 브랜치와 Pull Request로 합치고, 초기 QR 판독 기획과 현재 통화 후 대응 기획을 모두 저장소 문서로 남겼습니다. **팀 역할 내용 전원 확인**

## ⓕ 외부 자원 활용 내역

| 구분 | 명칭 | 용도 | 라이선스 |
|---|---|---|---|
| 오픈소스 | FastAPI 0.162, Uvicorn 0.54 | 서버 | MIT, BSD-3-Clause |
| 오픈소스 | boto3 1.43, httpx 0.28, pytest 9.2 | S3 연동, HTTP, 테스트 | Apache 2.0, BSD-3, MIT |
| 오픈소스 | anthropic 2.3, openai 3.42, langfuse 5.1 | API 클라이언트, 관측 | MIT, Apache 2.0, MIT |
| 오픈소스 | AndroidX WorkManager 2.9.1, DocumentFile 1.0.1 | 앱 주기 실행, 폴더 접근 | Apache 2.0 |
| 오픈소스 | Elasticsearch 8.17.0, analysis-nori | 사기 사례 검색, 한국어 분석 | Elastic License 2.0 |
| 오픈소스 | BAAI/bge-m3, sentence-transformers, PyTorch | 문서·질의 임베딩 | MIT, Apache 2.0, BSD-3 |
| 오픈소스 | elasticsearch-py, pypdf, python-dotenv | 색인, PDF 읽기, 설정 | Apache 2.0, BSD-3, BSD-3 |
| 오픈소스 | faster-whisper 1.2.1, CTranslate2 4.8.4, Whisper large-v3-turbo | 자체 STT 서버 (최종 선정) | MIT |
| 오픈소스 | Whisper large-v3, whisper-medium-komixv2 | STT 비교 평가 (미채택) | MIT, 모델 카드 표기 없음 |
| 오픈소스 | Qwen3-ASR 0.6B·1.7B, qwen-asr 0.0.6, Transformers 4.57 | STT 비교 평가 (미채택) | Apache 2.0 |
| 오픈소스 | SUIT 2.0.5, 나눔스퀘어 라운드, Lucide 0.460 | 폰트, 아이콘 | OFL, OFL, ISC |
| 외부 API | Anthropic claude-opus-5-5, claude-haiku-5-5 | 판정, 재순위, 시나리오 생성, 문서 구조화 | 상용 API |
| 외부 API | OpenAI whisper-1, gpt-image-2 | STT 대체 경로, 체험 가상 인물 사진 | 상용 API |
| 외부 API | Amazon S3, Langfuse Cloud | 음성 저장, 처리 시간·토큰 관측 | 상용 서비스 |
| 외부 API | Amazon Polly, ElevenLabs | STT 평가용 한국어 데이터셋, 자연스러운 음성 생성 | 상용 API |
| 사전 보유 코드 | 웹 화면 코드 index.html, css/, js/, assets/ (2026-10-30 01시경 작성, 주제 공개 전) | 공용 화면 자원과 초기 웹 MVP | 팀 자체 작성 |
| 기타 | Terraform, Docker | 검색 서버 구성 | BUSL 1.1, Apache 2.0 |
| 기타 | Claude Code **다른 도구 추가** | 코드·문서 작성 보조 | 상용 서비스 |
| 기타 | 금융당국 보도자료, KISA 118 상담 기반 합성 데이터 | 검색 문서 (원문 미저장, 요약만 적재) | 각 출처 이용 조건 |
| 기타 | 금감원 공개 녹음 전사(KorCCVi) | 내부 학습용. 검색 결과에서 제외 | 각 출처 이용 조건 |
| 기타 | 금융감독원·금융위원회 경보, 매일신문 보도 | 홈 화면 사기 동향 (출처 표시) | 출처 표시 인용 |

버전은 제출 환경 설치 버전 기준. 검색 서버 라이브러리는 requirements.txt 참고

ⓖ 기대 효과 및 실제 적용 가능성

# 할 수 있는 것과 아직 모르는 것을 나눠서 말합니다

## 기대 효과

- **혼자 판단하는 상태를 끊음** 경고, 112 연결, 가족 확인을 한 흐름으로 묶음
- **이체 경로를 시간으로 지연** 강한 의심 시 금융 앱을 잠가 생각할 시간을 확보
- **사생활을 지키는 가족 보호** 통화 내용 없이 의심 여부만 공유
- **AI 음성에 대응하는 습관** 목소리 대신 암구호로 확인

## 검증 상태

| 항목 | 상태 |
|---|---|
| 녹음 → STT → 판정 → 경고 → 잠금 | **실제 폰에서 확인** |
| 가족 알림, 암구호, 제보, 피드백 | **테스트·브라우저 확인** |
| STT 5개 설정 비교 (합성 음성 20개) | **turbo CER 3.33%, RTF 1.17** |
| 실제 MP3 → 자체 STT → 판정 → 잠금 | **실서버 확인** |
| 탐지율, 오탐률 | **미측정** |
| 실제 피해 감소 효과 | **미측정** |
| 사례 검색이 판정에 주는 효과 | **미측정** |

예시 대본 6건은 동작 확인용이며 성능 근거로 쓰지 않습니다. 앱의 피드백 기능으로 사람 판정 라벨을 쌓아 측정합니다.

제약: 삼성 통화 녹음만 지원, 인터넷 전화 제외, 접근성 권한을 끄면 잠금 불가

ⓖ 확장 가능성 — 추가 개발 방향

# 시연용 프로토타입에서 실제 서비스까지의 순서

1단계 · 출시 전제

## 안전하게 운영

- 서버 HTTPS 전환
- 음성 저장소 국내 리전 또는 국외 이전 고지
- FCM으로 가족 알림 지연 해소
- Play 접근성 정책 심사 대응

2단계 · 성능 증명

## 평가하고 보정

- 라벨 평가셋으로 탐지율·오탐률 측정
- 확신도 보정 후 임계값 재설정
- RAG 유무 비교
- GPU 서빙으로 대체 경로 사용 축소

3단계 · 범위 확대

## 제휴로 앞단 연결

- 제조사·통신사 실시간 탐지와 연동해 후속 조치만 제공
- 금융사 연계로 앱 차단 대신 이체 지연
- 삼성 외 녹음 환경 지원

**탐지 다음에 무엇을 할 것인가. CodySafe는 그 답을 가족과 함께 만듭니다.**

유사 후속 기능이 기존 실시간 탐지 서비스에 있는지는 추가 확인이 필요합니다.