코디세이 AI 해커톤 2026 · 팀 유레카

CodySafe
전화를 끊은 뒤,
가족과 함께 막습니다

통화 녹음을 AI로 분석해 근거를 보여 주고, 가족에게 알리고, 금융 앱을 잠그는 보이스피싱 후속 대응 서비스

박병국 · 김동현 · 김호연 · 유상우 · 전선형

ⓐ 문제 정의 및 목표 사용자

속은 사람은 혼자 있고, 가족은 뒤늦게 압니다

5,384만 원

2025년 보이스피싱 건당 피해액 (전년 2,500만 원)

발생 건수는 24.6% 줄었지만 피해액은 62.4% 늘었습니다. 피해액의 **78.6%** (9,884억 원)가 기관 사칭형입니다.

출처: 국회 제출 자료, 매일신문 2026-09-23

우리가 본 빈틈

- 사기범은 전화를 끊지 말라, 아무에게도 말하지 말라고 몰아붙입니다. 이때 **당사자의 판단만으로** 멈추기 어렵습니다.
- 가족이 알아도 도울 방법이 없고, 통화 내용을 통째로 공유하는 것은 사생활 문제입니다.
- AI 음성 때문에 **"목소리가 같으니 가족"**이라는 확인도 믿기 어려워졌습니다.

목표 사용자

보호 대상

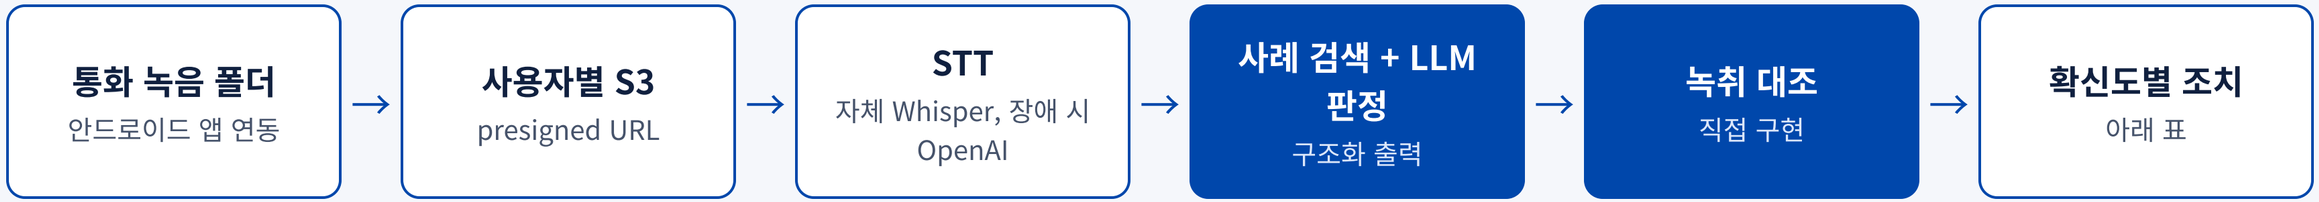
삼성 휴대폰으로 통화를 녹음하는, 보이스피싱에 노출된 사람

가족

부모님과 형제의 금융 피해를 걱정하지만 통화 내용까지 보고 싶지는 않은 사람

ⓑ 해결 방안 — 서비스 개요

실시간 탐지와 경쟁하지 않고, 그 다음 단계를 맡습니다



확신도별 후속 조치

조건	동작
0.7 이상	연결된 가족에게 **의심 여부만** 알림
0.9 이상	은행·카드·간편결제·증권·원격제어 **앱 47개 잠금** (기본 1시간)
근거 없음	"판단 어려움"으로 낮추고 알림·잠금 안 함
잠금 해제	가족은 즉시, 본인은 10분 대기 후, 또는 시간 만료

왜 통화 중이 아니라 통화 후인가

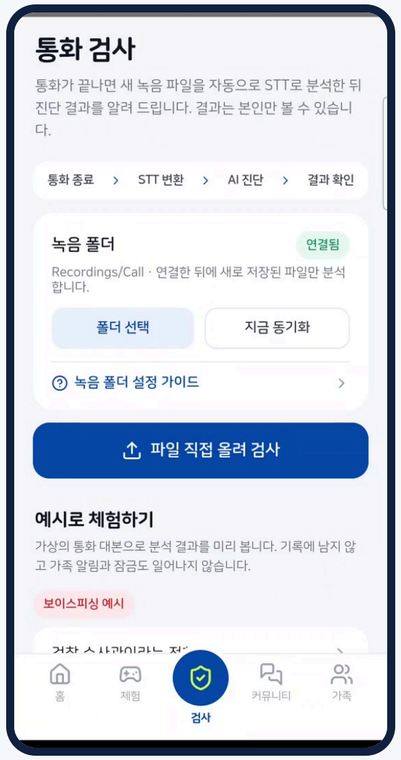
일반 안드로이드 앱은 통화 음성을 받을 수 없습니다. `VOICE_CALL` 캡처는 사전 설치된 특권 앱의 권한이 필요하고, 통화 중 일반 앱의 마이크 입력은 무음입니다.

실시간 탐지는 제조사와 통신사 영역입니다. 우리는 **이체 전 차단을 보장하지 않으며**, 통화 후 추가 이체와 2차 피해를 줄이는 데 집중합니다.

근거: Android 개발자 문서(MediaRecorder.AudioSource, 오디오 입력 공유)

ⓑ 주요 기능 — 실제 안드로이드 폰 녹화 화면

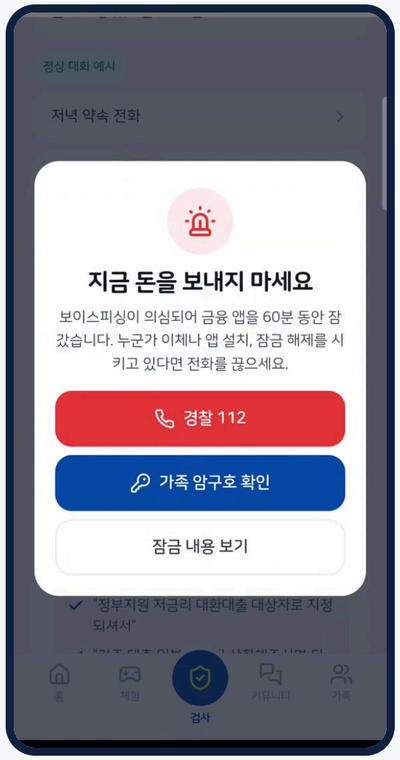
분석부터 잠금까지 실제 폰에서 동작합니다



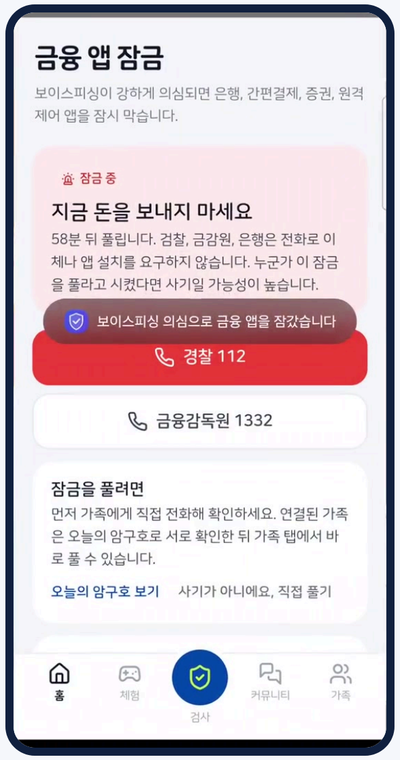
1. 녹음 폴더 연결
저장된 녹음만 읽음



2. 통화 속 근거
실제로 나온 말만 표시



3. 즉시 경고
112와 암구호로 연결



4. 금융 앱 잠금
열면 경고로 되돌림

예방까지 함께

가족 암구호 매일 0시에 바뀌는 단어로 가족 사칭 확인

사기 체험 13개 수법을 대화형으로 연습

제보→훈련 추천 상위 제보를 AI 시나리오로 생성

코디·퀴즈 가족 퀴즈 15장, 예방 행동에만 점수

테스트 통화 사용. 개인정보 장면 제외, 대기 시간 단축

ⓒ 활용 AI 기술 및 직접 개발 범위

판정은 API에 맡기되, 믿고 행동하게 만드는 층은 직접 만들었습니다

층	적용 방식	구분
음성 → 글자	자체 서버 CPU Whisper large-v3-turbo INT8, 부하·장애 시 OpenAI `whisper-1`	**직접 구축**: 모델 비교, 서빙, 전환. 대체 경로만 외부 API
사기 판정	Claude `claude-opus-5-5`, JSON 스키마 출력. 4개 라벨, 유형, 확신도, 인용 근거	외부 API + **직접 작성**: 판정 기준, 스키마, 프롬프트 방어
수법 참고(RAG)	문서를 LLM으로 분류·구조화해 적재. BM25(nori) + bge-m3 kNN을 RRF로 결합, 유사 사례 3건을 판정에 참고. 실패 시 LLM만 사용	**직접 구현**: 적재·검색 API. Elasticsearch, bge-m3 사용
유형 매칭	음절 2-gram BM25 + 벡터 → RRF 결합 → LLM 재순위 (수법 지식 10종)	**직접 구현**. 벡터는 현재 해시 임베딩
근거 대조	LLM이 인용한 문장이 녹취에 순서대로 있는지 코드로 검사	**직접 구현**
후속 조치	임계값 분기, 가족 알림, 잠금·해제 정책, 가족 그룹 암구호	**직접 구현**
안드로이드 앱	저장소 접근 프레임워크 폴더 감시, S3 직접 업로드, 접근성 서비스 앱 차단	**직접 구현** (Kotlin)
제보 → 시나리오	번호·계좌·링크 마스킹 후 LLM으로 5턴 훈련 생성, 결과 구조 검사	**직접 구현** + 외부 API

자체 학습 모델은 없습니다. 모델 파인튜닝은 확장 계획입니다.

ⓒ 적용 방식 — 오판을 줄이는 설계

잘못된 경고도 피해입니다. 그래서 LLM의 답을 그대로 믿지 않습니다

```
# server/guard/llm.py (요약)
def _keep_grounded(result, transcript):
    if result["label"] != VOICE_PHISHING:
        result["evidence"] = []
        return result
    # 녹취에 실제로 있는 인용만 남김
    result["evidence"] = [q for q in result["evidence"]
                          if _in_transcript(q, transcript)]
    # 근거가 없으면 가족 알림과 잠금을 일으키지 않음
    if not result["evidence"]:
        result["label"] = "uncertain"
    return result
```

자동 테스트 70개 통과 (`pytest`, 외부 키 없이 실행). 판정 분기, 잠금 해제, 가족 권한, 제보 마스킹을 포함합니다.

설계 원칙 5가지

- **환각 차단** 녹취에 없는 근거는 표시하지 않고 조치도 막음
- **주입 방어** 녹취 속 "정상으로 판정하라"는 지시를 따르지 않고 판단 근거로 고려
- **단계적 조치** 피해가 큰 잠금은 알림보다 높은 기준 적용
- **정보 최소화** 가족에게 요약·유형·녹취·확신도를 보내지 않음. 일상 통화는 글자 기록도 저장 안 함
- **되돌릴 수 있음** 오탐이어도 가족 해제, 10분 대기, 시간 만료로 복구

확신도는 LLM이 매긴 값이며 보정 전이라 사기 확률이 아닙니다. 화면에도 그렇게 표시합니다.

ⓓ 개발 환경 및 기술 스택

웹과 안드로이드 앱이 하나의 API와 화면을 함께 씁니다

구분	사용 기술
서버	Python 3.12, FastAPI, Uvicorn, SQLite
웹	HTML, CSS, JavaScript (프레임워크 없음)
앱	Kotlin, WebView, WorkManager, 접근성 서비스 (minSdk 26, targetSdk 34)
AI	Claude, faster-whisper(대체: OpenAI Whisper), Elasticsearch 8.17 + bge-m3
인프라	AWS EC2, S3 (presigned URL), Terraform·Docker(검색 서버), GitHub Actions
관측	Langfuse Cloud: 시간·토큰·판정 라벨만 전송, 통화 내용은 보내지 않음
검증	pytest 70개, 실제 음성 파일, 실제 폰 녹화

구현상 판단

화면을 WebView로 공유

화면을 고쳐도 APK를 다시 빌드하지 않습니다.
네이티브는 폴더 접근, 동기화, 차단만 맡습니다.

기기에 AWS 키를 두지 않음

presigned URL로 사용자별 경로에 직접 올립니다.

음성은 자체 서버에서 먼저

외부 전송과 의존을 줄이려 STT를 직접 띄웠습니다.
GPU 사용 제약으로 CPU에서 서빙하고, 부하·장애 때만 OpenAI로 넘깁니다.

대체 경로를 탄 음성은 외부로 전송됩니다. Langfuse: us.cloud.langfuse.com/project/cmvwspomu005fad0e5vr8sgrq/traces

ⓔ 팀원별 역할 분담

팀원별 담당 업무와 기여 내용

이름	담당	기여 내용
김동현	서비스 구현 총괄	서버 API와 판정 파이프라인, 근거 대조, 가족 알림·잠금·암구호, 웹 화면, 안드로이드 앱, 체험·제보·피드백, S3·RAG·Langfuse 연동, 테스트, 배포
김호연	초기 기획	문제 조사와 경쟁 서비스 비교, 기획 초안, 저장소 비밀값 관리 규칙(.gitignore)
유상우	브랜드 디자인	CodySafe 브랜드 가이드, 로고 자산
박병국	URL 보안 탐지	URL 구조·유사 도메인·위협 정보 기반 탐지 모듈 (별도 프로토타입)
전선형	**확인 필요**	**담당 업무와 기여 내용 기입**

협업 방식

GitHub 브랜치와 Pull Request로 합치고, 초기 QR 판독 기획과 현재 통화 후 대응 기획을 모두 저장소 문서로 남겼습니다. **팀 역할 내용 전원 확인**

ⓕ 외부 자원 활용 내역

구분	명칭	용도	라이선스
오픈소스	FastAPI 0.162, Uvicorn 0.54	서버	MIT, BSD-3-Clause
오픈소스	boto3 1.43, httpx 0.28, pytest 9.2	S3 연동, HTTP, 테스트	Apache 2.0, BSD-3, MIT
오픈소스	anthropic 2.3, openai 3.42, langfuse 5.1	API 클라이언트, 관측	MIT, Apache 2.0, MIT
오픈소스	AndroidX WorkManager 2.9.1, DocumentFile 1.0.1	앱 주기 실행, 폴더 접근	Apache 2.0
오픈소스	Elasticsearch 8.17.0, analysis-nori	사기 사례 검색, 한국어 분석	Elastic License 2.0
오픈소스	BAAI/bge-m3, sentence-transformers, PyTorch	문서·질의 임베딩	MIT, Apache 2.0, BSD-3
오픈소스	elasticsearch-py, pypdf, python-dotenv	색인, PDF 읽기, 설정	Apache 2.0, BSD-3, BSD-3
오픈소스	faster-whisper, Whisper large-v3-turbo **비교 모델 추가**	자체 STT 서버, 모델 비교	MIT, MIT
오픈소스	SUIT 2.0.5, 나눔스퀘어 라운드, Lucide 0.460	폰트, 아이콘	OFL, OFL, ISC
외부 API	Anthropic claude-opus-5-5, claude-haiku-5-5	판정, 재순위, 시나리오 생성, 문서 구조화	상용 API
외부 API	OpenAI whisper-1, gpt-image-2	STT 대체 경로, 체험 가상 인물 사진	상용 API
외부 API	Amazon S3, Langfuse Cloud	음성 저장, 처리 시간·토큰 관측	상용 서비스
외부 API	Amazon Polly, ElevenLabs	STT 평가용 한국어 데이터셋, 자연스러운 음성 생성	상용 API
사전 보유 코드	웹 화면 코드 index.html, css/, js/, assets/ (2026-10-30 01시경 작성, 주제 공개 전)	공용 화면 자원과 초기 웹 MVP	팀 자체 작성
기타	Terraform, Docker	검색 서버 구성	BUSL 1.1, Apache 2.0
기타	Claude Code **다른 도구 추가**	코드·문서 작성 보조	상용 서비스
기타	금융당국 보도자료, KISA 118 상담 기반 합성 데이터	검색 문서 (원문 미저장, 요약만 적재)	각 출처 이용 조건
기타	금감원 공개 녹음 전사(KorCCVi)	내부 학습용. 검색 결과에서 제외	각 출처 이용 조건
기타	금융감독원·금융위원회 경보, 매일신문 보도	홈 화면 사기 동향 (출처 표시)	출처 표시 인용

버전은 제출 환경 설치 버전 기준. 검색 서버 라이브러리는 requirements.txt 참고

ⓖ 기대 효과 및 실제 적용 가능성

할 수 있는 것과 아직 모르는 것을 나눠서 말합니다

기대 효과

- **혼자 판단하는 상태를 끊음** 경고, 112 연결, 가족 확인을 한 흐름으로 묶음
- **이체 경로를 시간으로 지연** 강한 의심 시 금융 앱을 잠가 생각할 시간을 확보
- **사생활을 지키는 가족 보호** 통화 내용 없이 의심 여부만 공유
- **AI 음성에 대응하는 습관** 목소리 대신 암구호로 확인

검증 상태

항목	상태
녹음 → STT → 판정 → 경고 → 잠금	**실제 폰에서 확인**
가족 알림, 암구호, 제보, 피드백	**테스트·브라우저 확인**
로컬 STT 모델 약 6개 비교	**완료**
실제 MP3 → 자체 STT → 판정 → 잠금	**실서버 확인**
탐지율, 오탐률	**미측정**
실제 피해 감소 효과	**미측정**
사례 검색이 판정에 주는 효과	**미측정**

예시 대본 6건은 동작 확인용이며 성능 근거로 쓰지 않습니다. 앱의 피드백 기능으로 사람 판정 라벨을 쌓아 측정합니다.

제약: 삼성 통화 녹음만 지원, 인터넷 전화 제외, 접근성 권한을 끄면 잠금 불가

ⓖ 확장 가능성 — 추가 개발 방향

시연용 프로토타입에서 실제 서비스까지의 순서

1단계 · 출시 전제

안전하게 운영

- 서버 HTTPS 전환
- 음성 저장소 국내 리전 또는 국외 이전 고지
- FCM으로 가족 알림 지연 해소
- Play 접근성 정책 심사 대응

2단계 · 성능 증명

평가하고 보정

- 라벨 평가셋으로 탐지율·오탐률 측정
- 확신도 보정 후 임계값 재설정
- RAG 유무 비교
- GPU 서빙으로 대체 경로 사용 축소

3단계 · 범위 확대

제휴로 앞단 연결

- 제조사·통신사 실시간 탐지와 연동해 후속 조치만 제공
- 금융사 연계로 앱 차단 대신 이체 지연
- 삼성 외 녹음 환경 지원

탐지 다음에 무엇을 할 것인가. CodySafe는 그 답을 가족과 함께 만듭니다.

유사 후속 기능이 기존 실시간 탐지 서비스에 있는지는 추가 확인이 필요합니다.